Московский государственный технический университет им. Н.Э. Баумана
Кафедра «Системы обработки информации и управления»

Рубежный контроль №1

Выполнил:
студент группы ИУ5-63М
Елизаров О. О.

_____

Москва — 2020 г.

Елизаров Олег Олегович, ИУ5-63, Вариант №6, Задание №1, Набор данных №6

1. Задание

Для заданного набора данных проведите корреляционный анализ. В случае наличия пропусков в данных удалите строки или колонки, содержащие пропуски. Сделайте выводы о возможности построения моделей машинного обучения и о возможном вкладе признаков в модель

2. Дополнительное задание

Для произвольной колонки данных построить график “Ящик с усами (boxplot)”

3. Решение

Подключим необходимые библиотеки и загрузим набор данных

[1]:
```
import numpy as np
import pandas as pd
import seaborn as sns
import string
import matplotlib.pyplot as plt
from sklearn.model_selection import train_test_split
from sklearn.neighbors import KNeighborsRegressor, KNeighborsClassifier
from sklearn.metrics import accuracy_score, balanced_accuracy_score
from sklearn import preprocessing
from sklearn.linear_model import LinearRegression
import math
from sklearn import utils
from typing import Dict, Tuple
%matplotlib inline
sns.set(style="ticks")
```

Загрузка данных

[ ]:
```
#
data = pd.read_csv('./Admission_Predict.csv', sep=",")
```

Параметры данных.Количество строк и стобцов

[3]:
```
#         .
data.shape
```

[3]:
```
(400, 9)
```

[4]:
```
for col in data.columns:
    #                  -
    temp_null_count = data[data[col].isnull()].shape[0]
    print('{} - {}'.format(col, temp_null_count))
print('    ,             ')
```

```
Serial No. - 0
GRE Score - 0
TOEFL Score - 0
University Rating - 0
SOP - 0
LOR  - 0
CGPA - 0
Research - 0
Chance of Admit  - 0
```

,

Треугольный вариант матрицы корреляции

[5]:
```
#
mask = np.zeros_like(data.corr(), dtype=np.bool)
mask[np.tril_indices_from(mask)] = True
sns.heatmap(data.corr(method='spearman'), mask=mask, annot=True, fmt='.2f')
```

[5]: <matplotlib.axes._subplots.AxesSubplot at 0x1efc2ce9c08>

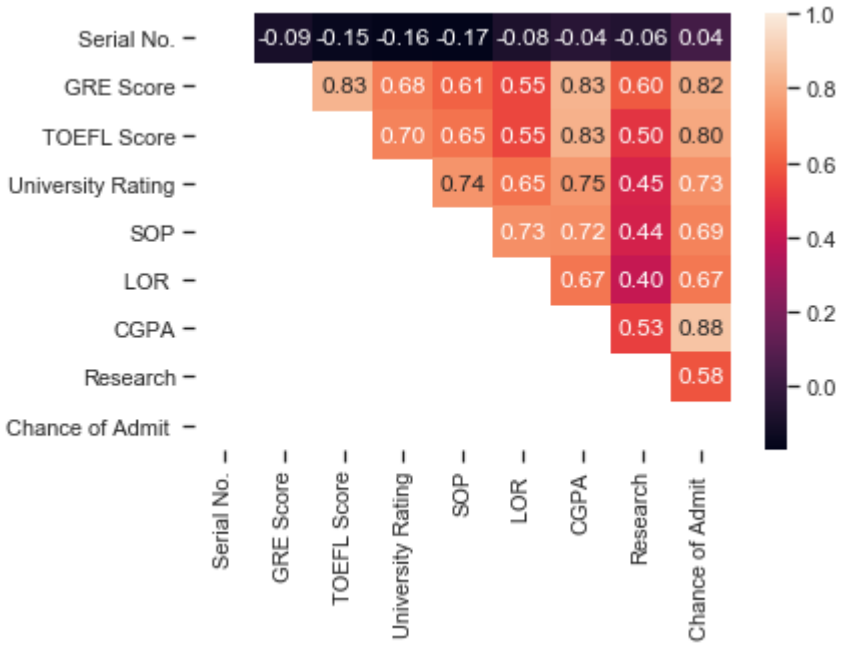

Закрадываются подозрения на связь CGPA-Chance of Admit

[6]:
```
data.columns
data.head()
```

[6]:

	Serial No.	GRE Score	TOEFL Score	University Rating	SOP	LOR	CGPA	\
0	1	337	118	4	4.5	4.5	9.65	
1	2	324	107	4	4.0	4.5	8.87	
2	3	316	104	3	3.0	3.5	8.00	
3	4	322	110	3	3.5	2.5	8.67	
4	5	314	103	2	2.0	3.0	8.21	

```
   Research  Chance of Admit
0         1              0.92
1         1              0.76
2         1              0.72
3         1              0.80
4         0              0.65
```

[7]:
```
fig, ax = plt.subplots(figsize=(10,10))
sns.scatterplot(ax=ax, x='CGPA', y='Chance of Admit ', data=data,␣
↪hue='University Rating')
```

-

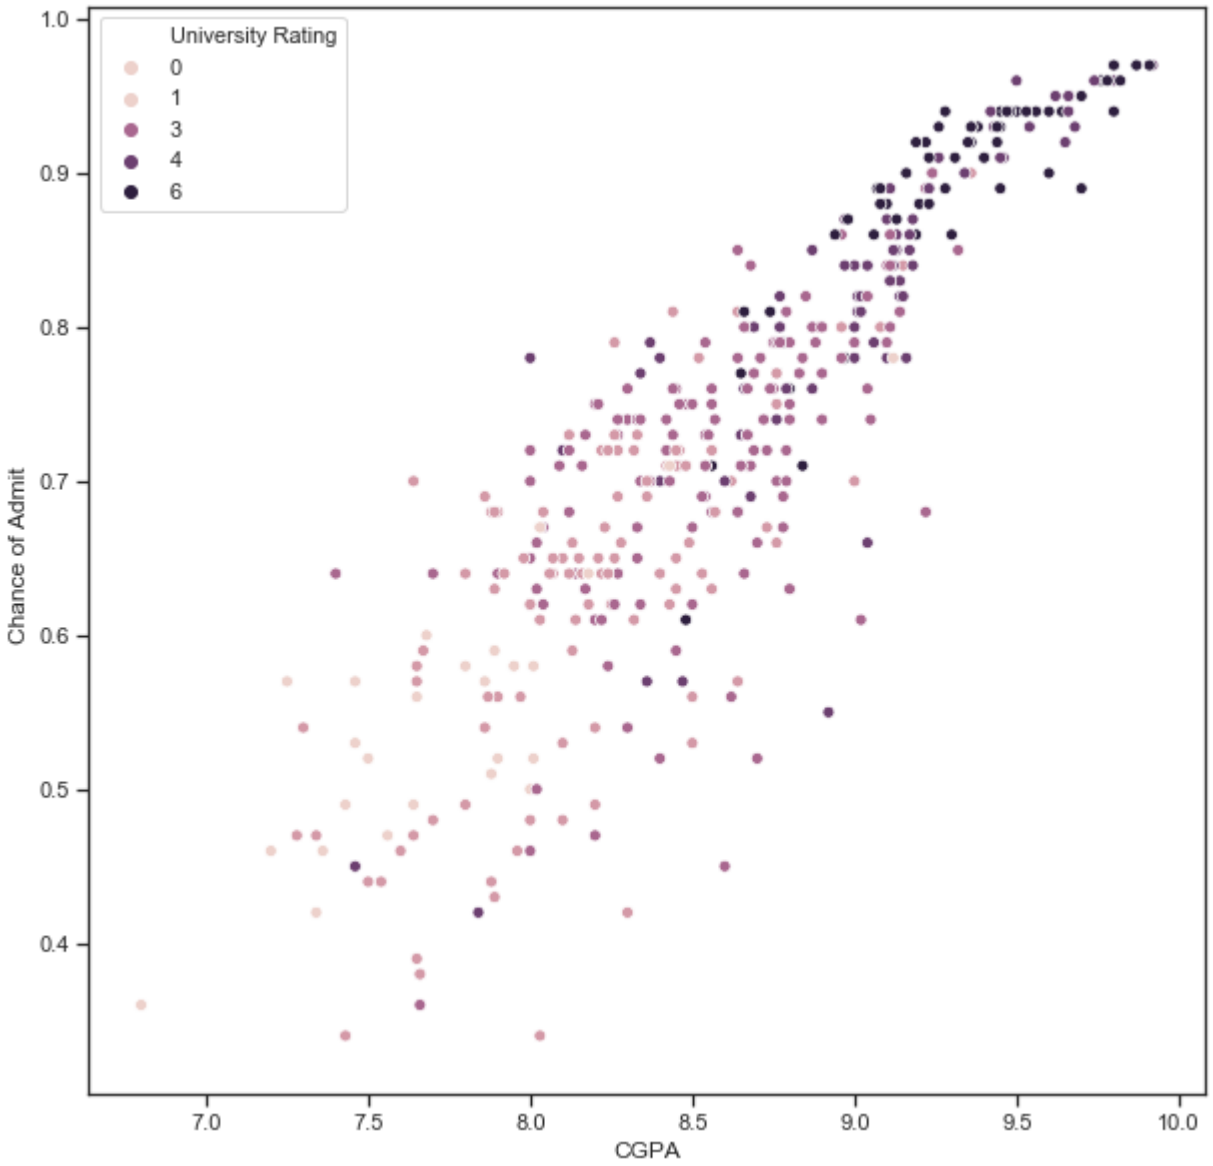

Чем-то похоже на функцию вида y=x

[8]:
```
#
def analytic_regr_coef(x_array : np.ndarray,
```

```
                        y_array : np.ndarray) -> Tuple[float, float]:
    x_mean = np.mean(x_array)
    y_mean = np.mean(y_array)
    var1 = np.sum([(x-x_mean)**2 for x in x_array])
    cov1 = np.sum([(x-x_mean)*(y-x_mean) for x, y in zip(x_array, y_array)])
    b1 = cov1 / var1
    b0 = y_mean - b1*x_mean
    return b0, b1
```

[9]:
```
x_array = data['CGPA'].values
y_array = data['Chance of Admit '].values
```

Наши коэффициенты

[10]:
```
b0, b1 = analytic_regr_coef(x_array, y_array)
b0, b1
#
```

[10]:
```
(-1.0715116629341392, 0.20884722950068055)
```

[11]:
```
#             y       x
def y_regr(x_array : np.ndarray, b0: float, b1: float) -> np.ndarray:
    res = [b1*x+b0 for x in x_array]
    return res
```

[12]:
```
y_array_regr = y_regr(x_array, b0, b1)
```

[13]:
```
plt.plot(x_array, y_array, 'g.')
plt.plot(x_array, y_array_regr, 'b', linewidth=2.0)
plt.show()
print('                          ')
```

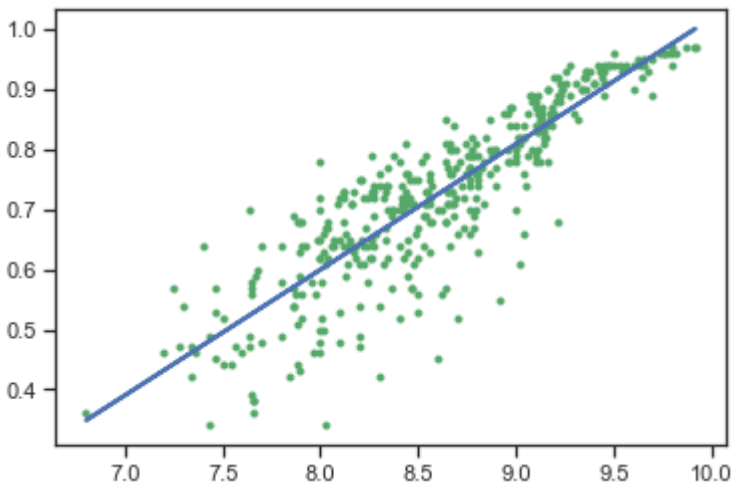

Линейная зависимость действительно заметна

[14]:
```
reg1 = LinearRegression().fit(x_array.reshape(-1, 1), y_array.reshape(-1,␣
↪1))
(b1, reg1.coef_), (b0, reg1.intercept_)
```

[14]:
```
((0.20884722950068055, array([[0.20884723]])),
 (-1.0715116629341392, array([-1.07151166])))
```

[15]:
```
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import PolynomialFeatures
```

[16]:
```
poly_model = Pipeline([('poly', PolynomialFeatures(degree=2)),
                       ('linear', LinearRegression(fit_intercept=False))])
```

[17]:
```
poly_model.fit(x_array.reshape(-1, 1), y_array)
```

[17]:
```
Pipeline(memory=None,
         steps=[('poly',
                 PolynomialFeatures(degree=2, include_bias=True,
                                    interaction_only=False, order='C')),
                ('linear',
                 LinearRegression(copy_X=True, fit_intercept=False,␣
↪n_jobs=None,
                                  normalize=False))],
         verbose=False)
```

[18]:
```
poly_y_pred = poly_model.predict(x_array.reshape(-1, 1))
```

Посмотрим как будет выглядеть квадратичный аппроксимирующий полином

[19]:
```
plt.plot(x_array, y_array, 'g.')
plt.plot(x_array, y_array_regr, 'b', linewidth=2.0)
plt.plot(x_array, poly_y_pred, 'r', linewidth=1.5)
plt.show()
print('                                          ')
```

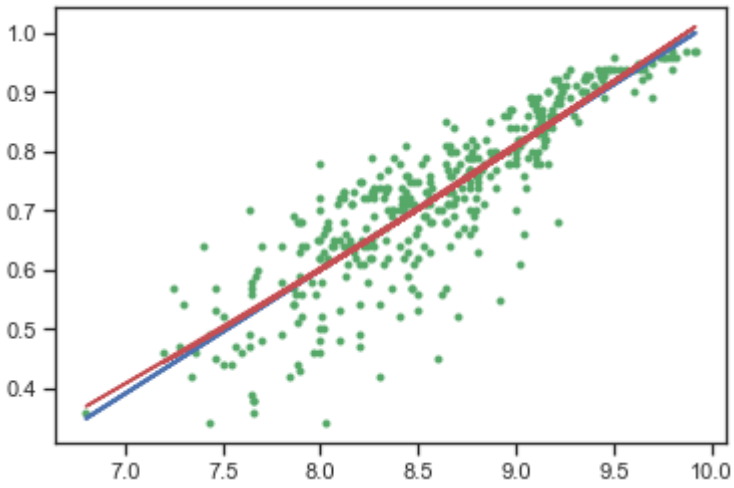

Дополнительное задание по boxplot'у

[20]:
```
sns.boxplot(x=data['Chance of Admit '])
print('boxplot')
```

```
boxplot
```

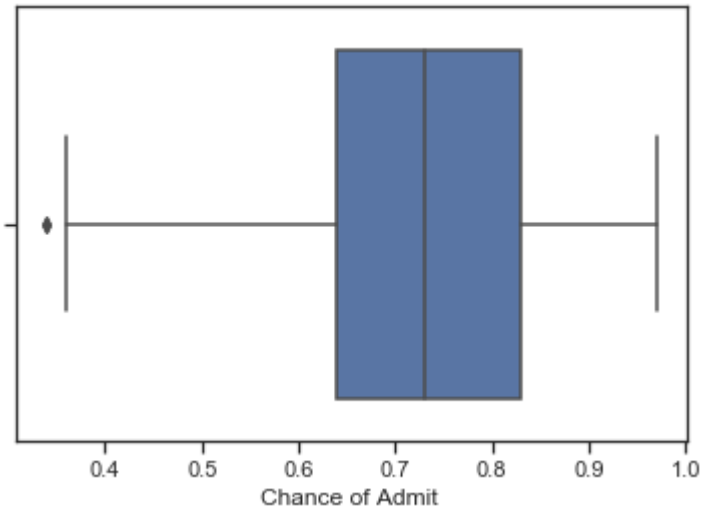

[21]:
```
sns.boxplot(x=data['CGPA'])
print('boxplot')
```

```
boxplot
```

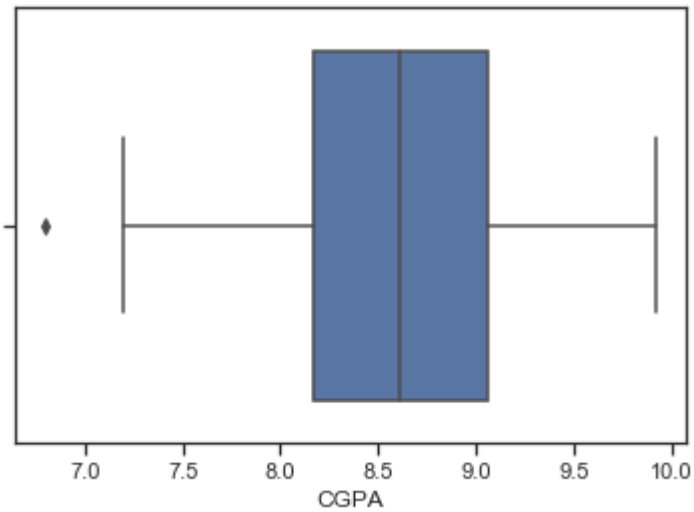

[ ]:
```

```

Плотность вероятности распределения данных

[22]:
```
fig, ax = plt.subplots(figsize=(10,10))
sns.distplot(data['CGPA'])
print('                          ')
```

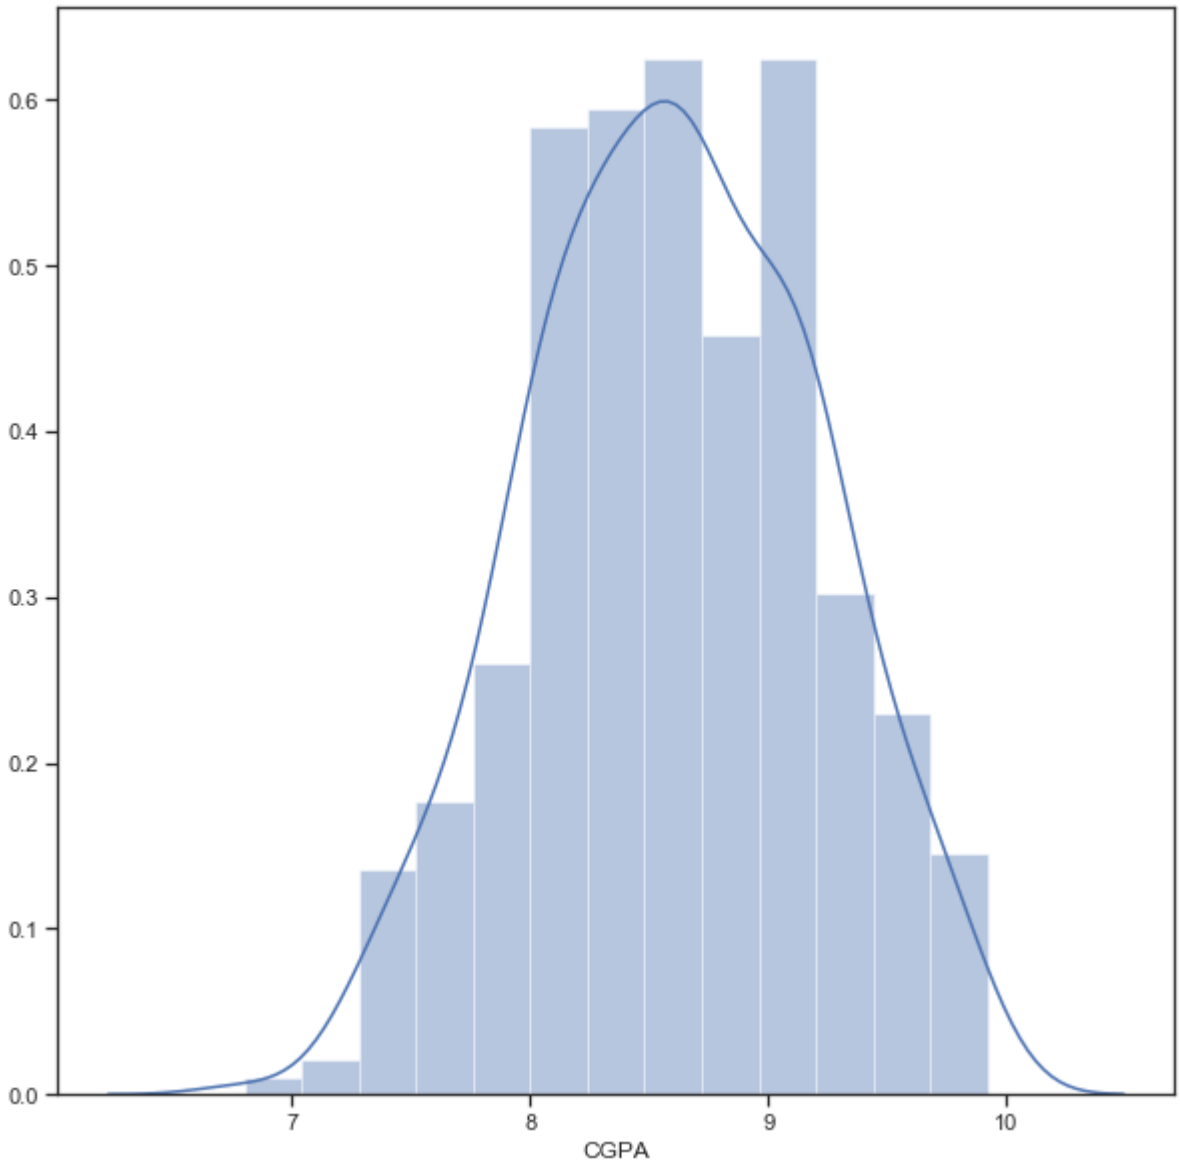

[23]:
```
fig, ax = plt.subplots(figsize=(10,10))
sns.distplot(data['Chance of Admit '])
print('                          ')
```

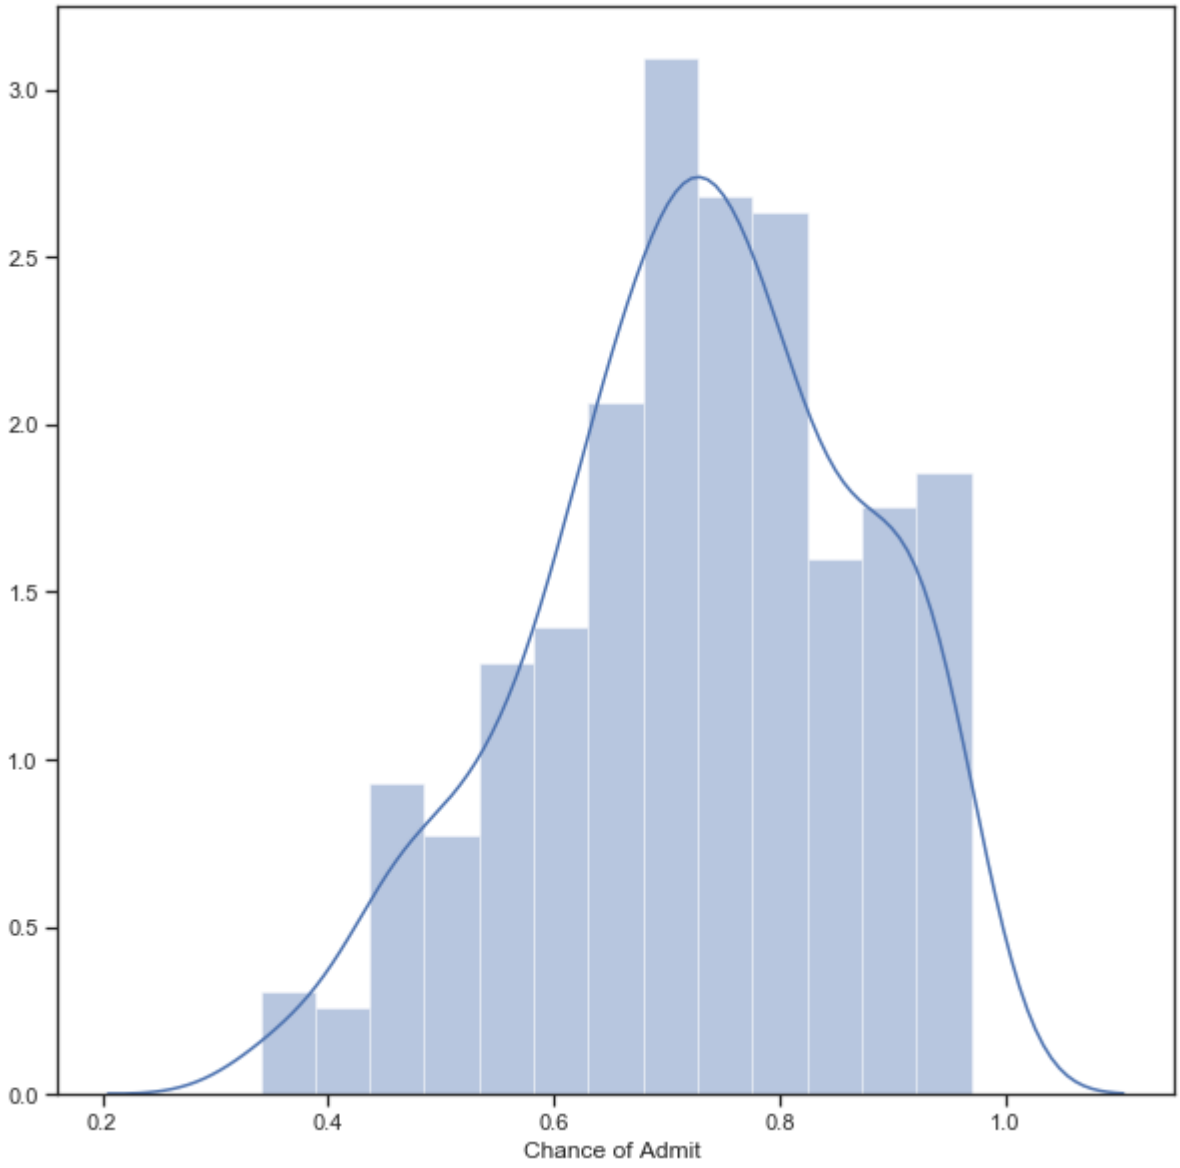

[24]:
```
data.groupby("University Rating").mean()#.plot.pie(y='Chance of Admit',figsize = (10,10))
```

[24]:

University Rating	Serial No.	GRE Score	TOEFL Score	SOP	LOR	CGPA	Research	Chance of Admit
1	233.807692	303.153846	99.076923	1.884615	2.211538	7.745769	0.192308	0.548077
2	214.813084	309.177570	103.523364	2.705607	2.925234	8.183738	0.299065	0.625981
3	204.165414	315.954887	106.887218	3.364662	3.402256	8.552256	0.533835	0.711880
4	199.594595	324.824324	111.824324	4.108108	4.006757	9.021622	0.797297	0.818108
5	153.533333	328.333333	113.666667	4.500000	4.358333			

```
5                  9.291167  0.866667          0.888167
```

[25]:
```
admit_df = pd.DataFrame(data= np.c_[data['CGPA'], data['GRE␣
↪Score'],data['Chance of Admit ']],columns=['Avg score by sem']+['Recom␣
↪exam score']+['Chance'])
```

[26]:
```
admit_df.describe()
```

[26]:

	Avg score by sem	Recom exam score	Chance
count	400.000000	400.000000	400.000000
mean	8.598925	316.807500	0.724350
std	0.596317	11.473646	0.142609
min	6.800000	290.000000	0.340000
25%	8.170000	308.000000	0.640000
50%	8.610000	317.000000	0.730000
75%	9.062500	325.000000	0.830000
max	9.920000	340.000000	0.970000

[27]:
```
admit_df.head()
```

[27]:

	Avg score by sem	Recom exam score	Chance
0	9.65	337.0	0.92
1	8.87	324.0	0.76
2	8.00	316.0	0.72
3	8.67	322.0	0.80
4	8.21	314.0	0.65

Среднеквадратичное отклонение между нашими параметрами

[32]:
```
sqr=0
for elem in admit_df.iterrows():
    sqr+=(elem[1][0]-elem[1][2]*10)**2
print(math.sqrt(sqr/admit_df.shape[0]))
print('                                ')
```

```
1.6549792294769134
```

На основании всех полученных данных можно сделать следующие выводы 1) Самую большую связь друг с другом имеют колонки: CGPA,TOEFL Score и Chance of Admit 2) Колонки Research(в меньшей степени) и Serial No(в большей степени) слабо связаны с остальными данными и могут быть удалены 3) Колонки CGPA и Chance of Admit имеют почти линейную зависимость , а следовательно методы линейной регрессии будут максимально эффективны для исследования.